Natural Language Processing المعالجة اللغوية الطبيعية

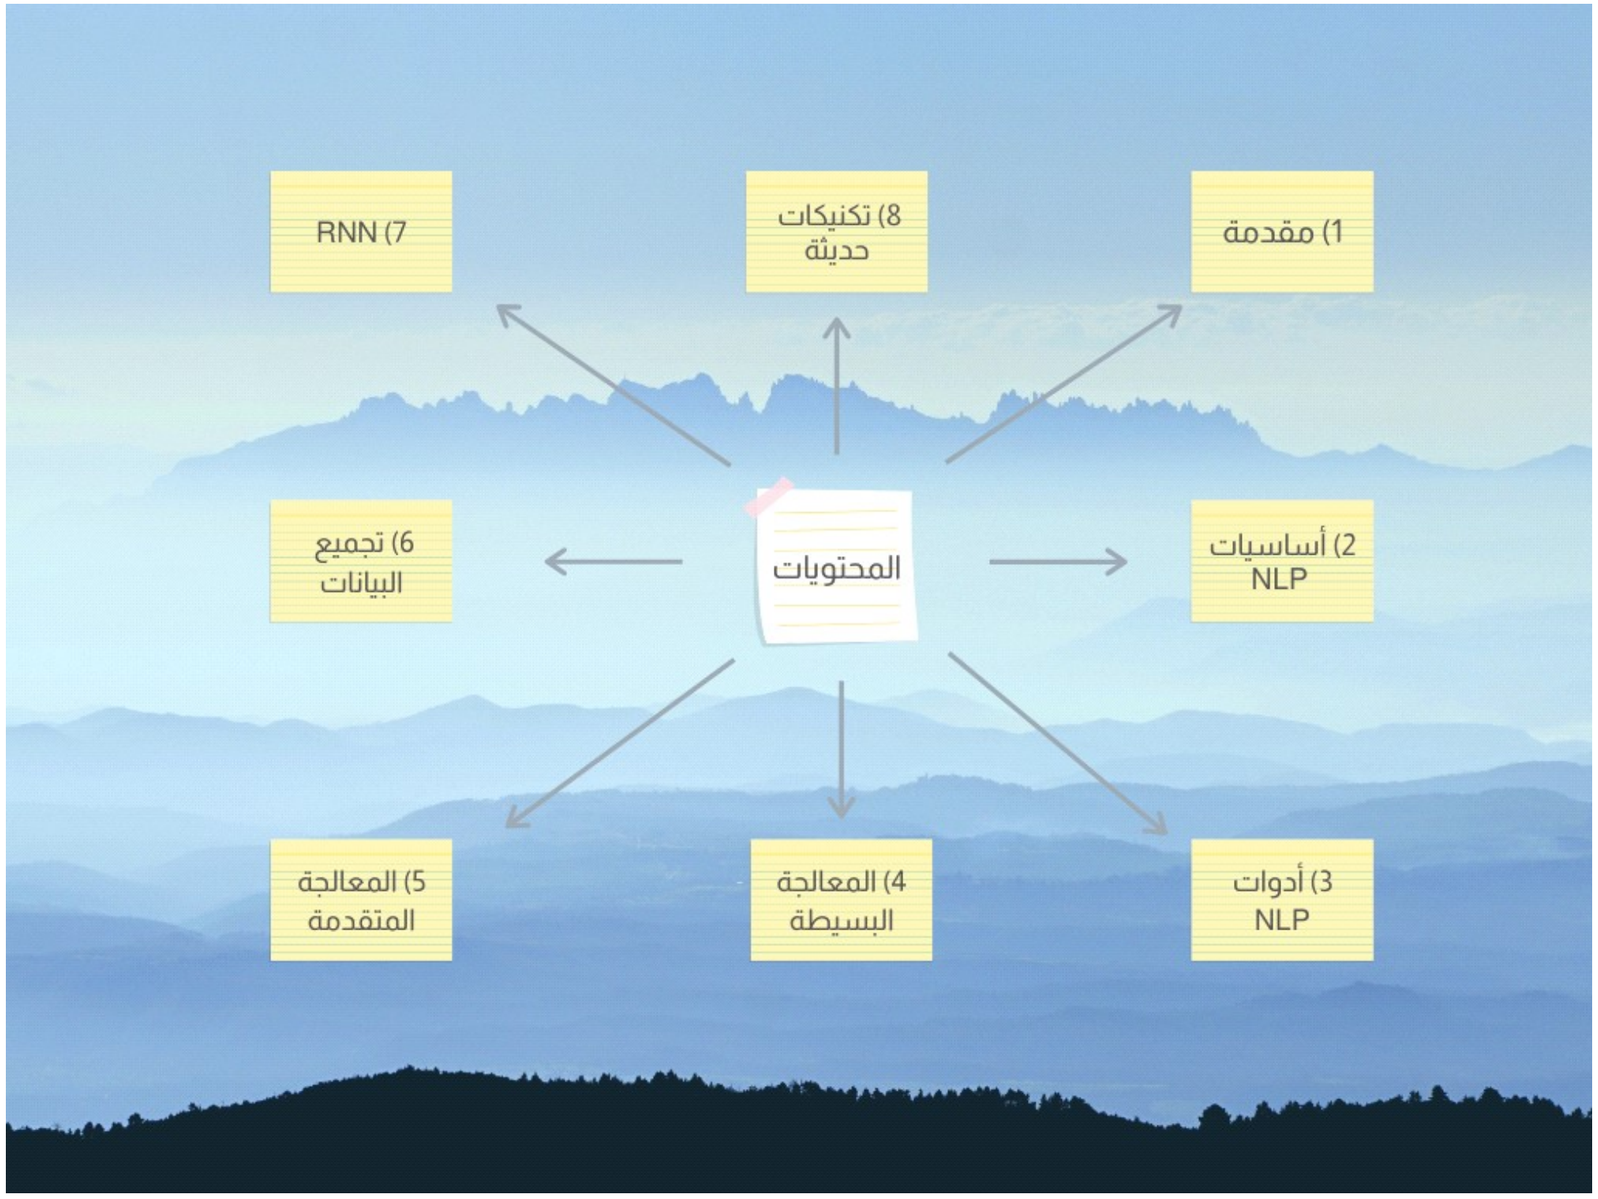

المحتويات

القسم الخامس : المعالجة المتقدمة للنصوص

الجزء الرابع : Non-Negative Matrix Factorization

==========

الـ **Non-Negative Matrix Factorization** أو **تحليل المصفوفة الموجبة** وهو اسلوب مشابه في مهمة تصنيف النصوص مثل LDA لكن مختلف نوعا في الفكرة , وهو اسرع و قد يكون ادق

و يعتمد في فكرته علي عمل مصفوفتين من ارقام عشوائية , واحدة هي العلاقة بين الكلمات و الموضوع , والثانية بين الموضوع و الـ clutser , والتي تكون الأساس الرياضي لتصنيف النصوص كما حدث في LDA

وهو يستخدم في NLP و ايضا في تطبيقات image processing

و الكود مشابه الي حد كبير الكود السابق هكذا . .

-

اولا نقرا الداتا

```
import pandas as pd
npr = pd.read_csv('npr.csv')
npr.head()
```

بدلا من عمل خطوة countvectorizer ثم LDA , نقوم باستدعاء Tfidf لاستخدامها

```
from sklearn.feature_extraction.text import TfidfVectorizer
tfidf = TfidfVectorizer(max_df=0.95, min_df=2, stop_words='english')
dtm = tfidf.fit_transform(npr['Article'])
```

ثم نستخدم NMF و هي اختصار Nonnegative Matrix Factorization

```
from sklearn.decomposition import NMF
nmf_model = NMF(n_components=7,random_state=42)
nmf_model.fit(dtm)
```

ثم نفس الخطوات السابقة

```
len(tfidf.get_feature_names())

import random
for i in range(10):
    random_word_id = random.randint(0,54776)
    print(tfidf.get_feature_names()[random_word_id])

len(nmf_model.components_)

nmf_model.components_

len(nmf_model.components_[0])

single_topic = nmf_model.components_[0]
```

```
single_topic.argsort()

single_topic[18302]

single_topic[42993]

single_topic.argsort()[-10:]

top_word_indices = single_topic.argsort()[-10:]

for index in top_word_indices:
    print(tfidf.get_feature_names()[index])

for index,topic in enumerate(nmf_model.components_):
    print(f'THE TOP 15 WORDS FOR TOPIC #{index}')
    print([tfidf.get_feature_names()[i] for i in topic.argsort()[-15:]])
    print('\n')
```

```
dtm.shape

len(npr)

topic_results = nmf_model.transform(dtm)

topic_results.shape

topic_results[0].round(2)

topic_results[0].argmax()

npr.head()

topic_results.argmax(axis=1)

npr['Topic'] = topic_results.argmax(axis=1)
```

```
topicdict  = {0:'health',1:'election',2:'legis',3:'policy',4:'candidates',5:'music',6:'educaion'}

npr['Topic Label'] = npr['Topic'].map(topicdict)

npr.head(10)
```